Réduction de dimensions en apprentissage non supervisé

Comparaison entre Analyse en Composantes Principales et Autoencodeurs

Auteurs :

Clovis Retif, Cyrian Revel–Hidalgo, Ethan Bochereau,
Ewen Crepin, Kosso Adoum-Kosso, Noé Dufour

Tuteur :

M. Vincent Couallier

9 avril 2026

Table des matières

1 Introduction **2**

2 Notations **3**

3 Analyse en Composantes Principales **3**
3.1 Préambule : Intuition géométrique . . . 3
3.2 Cadre théorique . . . 3
3.2.1 Formulation géométrique et maximisation de la variance . . . 4
3.2.2 Inertie projetée et conservation de l'information . . . 4
3.3 Application aux données de Périgueux . . . 4
3.3.1 Éboulis des valeurs propres . . . 5
3.3.2 Cercle des corrélations . . . 5
3.3.3 Projeté des individus et validation . . . 6
3.3.4 Synthèse des déductions environnementales . . . 7
3.4 Conclusion sur l'ACP . . . 8

4 Autoencodeurs **9**
4.1 De l'ACP aux autoencodeurs . . . 9
4.2 Cadre théorique et architecture . . . 9
4.2.1 Architecture formelle et nombre de paramètres . . . 9
4.2.2 Optimisation du modèle . . . 10
4.2.3 Le théorème de Baldi et Hornik . . . 10
4.2.4 Choix stratégique des fonctions d'activation . . . 11
4.3 Application et validation empirique . . . 11
4.3.1 L'autoencodeur linéaire . . . 11
4.3.2 L'autoencodeur non-linéaire à une couche (`tanh`) . . . 12
4.3.3 L'autoencodeur non-linéaire profond (`tanh`) . . . 12
4.4 Analyse comparative finale . . . 12
4.5 Conclusion générale . . . 13

5 Difficultés rencontrées et Organisation du groupe **14**
5.1 Défis techniques et limites des modèles . . . 14
5.2 Organisation du travail de groupe . . . 14

6 Références **15**

Annexe A : Démonstrations mathématiques **16**

Annexe B : Graphiques en haute résolution **19**

1 Introduction

Dans le contexte actuel de prolifération des données, l'analyse et le traitement de l'information sont devenus des enjeux majeurs en mathématiques appliquées et en science des données. Très souvent, les jeux de données recueillis se caractérisent par un grand nombre de variables. Cette grande dimensionnalité peut dégrader les performances des algorithmes d'apprentissage et rendre l'interprétation des résultats très complexe. L'apprentissage non supervisé, et plus particulièrement la réduction de dimension, offre des outils mathématiques puissants pour pallier ces difficultés en extrayant l'information essentielle (ou l'espace latent) d'un jeu de données, tout en minimisant la perte d'information.

C'est dans cette optique que s'inscrit notre projet *"Réduction de dimensions en apprentissage non supervisé : comparaison entre Analyse en Composantes Principales (ACP) et Autoencodeurs"*. L'objectif de ce travail est de confronter deux approches fondamentalement différentes permettant d'atteindre ce même but de réduction :

— D'une part, l'**Analyse en Composantes Principales (ACP)**, une méthode linéaire classique d'analyse de données reposant sur l'algèbre linéaire.

— D'autre part, les **Autoencodeurs**, une méthode non linéaire issue du domaine de l'apprentissage profond (*Deep Learning*) qui permet de capturer des relations complexes et non linéaires que l'ACP ne saurait modéliser.

Pour illustrer et comparer concrètement ces deux méthodes, nous nous appuierons sur un jeu de données réel recensant des observations environnementales dans la ville de Périgueux. Les individus de ce jeu de données sont des variables mesurées simultanément à un instant t :

— **Météorologiques :** température, pression atmosphérique, humidité, point de rosée, vitesse et direction du vent, ainsi que diverses mesures de précipitations (pluie).

— **Qualité de l'air (polluants) :** concentrations en dioxyde d'azote (NO_2), en particules fines (PM_{10}), en ozone (O_3) et en monoxyde d'azote (NO).

L'étude de ce jeu de données est particulièrement pertinente pour notre problématique. En effet, la météorologie et la pollution atmosphérique sont des phénomènes physiques fortement corrélés (par exemple, la température et l'ensoleillement influencent la formation de l'ozone, tandis que le vent disperse les particules). De fait, l'information contenue dans ces nombreuses variables est très redondante. La réduction de dimension doit nous permettre d'isoler des "profils types" de conditions climatiques et de qualité de l'air, en projetant ces observations dans un espace de dimension inférieure (un espace latent).

Pour mener à bien cette étude comparative, notre compte rendu s'articulera en deux grandes parties adoptant une structure analytique similaire. Dans un premier temps, nous nous concentrerons sur l'Analyse en Composantes Principales. Nous en détaillerons rigoureusement le cadre mathématique et théorique avant de l'appliquer à notre jeu de données (conjointement sur R avec la librairie *FactoMineR* et sur Python pour la génération de graphiques avancés). Dans un second temps, nous aborderons les Autoencodeurs en conservant cette même démarche. Nous exposerons la théorie sous-jacente avant de réaliser notre implémentation numérique. Enfin, nous conclurons sur l'efficacité des Autoencodeurs en dressant une comparaison critique vis-à-vis des résultats et des limites préalablement identifiés avec l'ACP.

2 Notations

L'Analyse en Composantes Principales (ACP) et les Autoencodeurs s'appliquent à des tableaux croisant des individus et des variables quantitatives. Pour comparer ces deux méthodes avec rigueur, nous adopterons les notations mathématiques suivantes tout au long du rapport :

n	Nombre d'individus (observations)	q	Dimension de l'espace latent (espace réduit)
p	Nombre de variables initiales	Γ	Matrice de corrélation
X	Matrice de nos données brutes ($n \times p$)	λ_i	i-ème valeur propre de Γ
Z	Matrice des données centrées et réduites	u_i	Vecteur propre associé à λ_i
z_i	L'individu i initial (vecteur ligne)	W_i	Matrices de poids numéro i (Encodeurs / Décodeurs)
$\hat{z}_i$	L'individu i reconstruit par le modèle	$\mathcal{L}$	Fonction de coût (MSE)

3 Analyse en Composantes Principales

3.1 Préambule : Intuition géométrique

L'objectif de l'Analyse en Composantes Principales (ACP) s'appréhende bien par contraste avec la régression linéaire. Alors que la régression cherche à expliquer une variable y par une variable x en minimisant les *écarts verticaux* (approche asymétrique), l'ACP traite toutes les variables symétriquement. Elle cherche le sous-espace qui minimise les *distances orthogonales* entre les points et leurs projections. D'après le théorème de Pythagore, minimiser cette distance résiduelle revient strictement à trouver l'axe sur lequel la projection des points est la plus étalée, c'est-à-dire l'axe qui **maximise la variance**.

3.2 Cadre théorique

Forts de cette distinction géométrique entre la distance verticale de la régression et la distance orthogonale, nous pouvons à présent formaliser le problème de l'ACP. Puisque notre but n'est pas d'expliquer une variable cible (approche supervisée) mais de résumer la structure globale de notre jeu de données, l'objectif est de projeter nos observations initialement en dimension p dans un sous-espace vectoriel E_q de dimension réduite q (avec $q < p$). Ce sous-espace (latent) optimal est précisément celui qui minimise la somme des distances orthogonales résiduelles, c'est-à-dire celui qui capture le maximum de l'information (la variance) initiale.

Pour que toutes nos variables météorologiques et de pollution pèsent d'un poids égal dans l'analyse, indépendamment de leurs unités de mesure, nous ne travaillons pas directement sur la matrice brute X, ni seulement sur la matrice centrée Y, mais sur la matrice des données centrées et réduites Z. D'un point de vue algébrique, cette standardisation implique que notre analyse repose sur la diagonalisation de la **matrice de corrélation** Γ, et non sur la matrice de variance-covariance, neutralisant ainsi totalement les effets d'échelle initiaux.

3.2.1 Formulation géométrique et maximisation de la variance

On cherche un sous-espace vectoriel E_q de dimension q (avec $q < p$), défini par une base orthonormée de vecteurs regroupés dans une matrice U_q, qui minimise la somme des distances orthogonales résiduelles des individus z_i.

Comme détaillé dans l'**Annexe A.1**, minimiser cette distance de projection revient mathématiquement à maximiser la variance projetée, c'est-à-dire maximiser la quantité $Tr(U_q^T \Gamma U_q)$, où Γ est la matrice de corrélation de nos données.

La résolution de ce problème d'optimisation sous contrainte aboutit à l'équation aux valeurs propres fondamentale :

$$\Gamma u_k = \lambda_k u_k$$

La recherche de notre sous-espace principal optimal revient donc simplement à identifier les q vecteurs propres associés aux q plus grandes valeurs propres ordonnées $\lambda_1 \geq \cdots \geq \lambda_q$ de la matrice Γ.

3.2.2 Inertie projetée et conservation de l'information

Une fois le sous-espace principal déterminé, les axes de projection sont naturellement ordonnés selon les valeurs propres décroissantes $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$. Chaque valeur propre λ_i quantifie exactement la part de variance du nuage de points initial qui est capturée (ou "projetée") sur le i-ème axe.

Afin d'interpréter la pertinence de chaque composante, nous utilisons le ratio de variance :

$$\frac{\lambda_i}{\sum_{j=1}^{p} \lambda_j}$$

Ce ratio exprime le pourcentage d'information conservé sur l'axe i par rapport à l'inertie totale du système (qui correspond à la somme de toutes les valeurs propres).

D'un point de vue analytique, cette mesure est cruciale pour l'interprétation. Un axe concentrant une forte proportion de l'inertie totale résume à lui seul une dynamique majeure ou un profil structurel fort au sein de notre jeu de données (par exemple, des corrélations intenses entre certaines variables météorologiques et les pics de pollution).

À l'inverse, les derniers axes, associés à des valeurs propres quasi nulles, ne capturent souvent que du bruit résiduel. Ainsi, l'étude de l'inertie projetée ne sert pas uniquement à tronquer notre espace de représentation ; elle nous permet d'évaluer concrètement la qualité de notre réduction de dimension et d'avoir une mesure mathématique exacte de l'information sauvegardée (et perdue) lors du passage de notre espace initial de dimension p vers l'espace latent.

3.3 Application aux données de Périgueux

Notre objectif est maintenant d'appliquer l'ACP sur les données de pollution atmosphérique de Périgueux afin d'analyser la relation entre les divers paramètres météorologiques et la pollution dans l'air. Pour réaliser cela, nous avons utilisé la librairie *FactoMineR* sous R. Cette librairie facilite grandement le travail en encapsulant les calculs d'algèbre linéaire détaillés précédemment. [11]

3.3.1 Éboulis des valeurs propres

Mise en œuvre : Dans cette étape, la fonction `PCA()` du package *FactoMineR* calcule la matrice de corrélation de nos données standardisées, puis en extrait les valeurs propres. L'éboulis, généré visuellement via la fonction `fviz_eig()` du package *factoextra*, trace ces valeurs sous forme d'histogramme. Chaque barre représente un axe factoriel (une composante principale), classé par ordre d'importance décroissante en termes de variance expliquée.

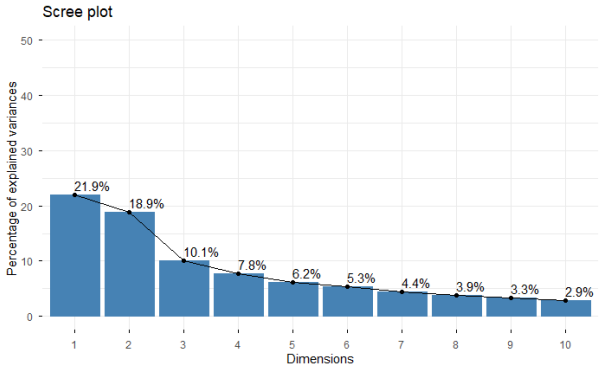


FIGURE 1 – Éboulis des valeurs propres indiquant le pourcentage d'information conservée par chaque axe.

Analyse et interprétation : L'objectif de cette section est de déterminer si notre ACP résume fidèlement la réalité complexe du jeu de données. Pour cela, on analyse si le plan factoriel principal (Axes 1 et 2) conserve un fort pourcentage de l'information totale. Si ce cumul est suffisant (par exemple, supérieur à 40 ou 50 %), nous pouvons affirmer que notre projection en deux dimensions constitue un excellent résumé analytique, avec une perte acceptable d'information.

3.3.2 Cercle des corrélations

Rappels théoriques : Les coordonnées de la variable X_j sur l'axe k dans le cercle des corrélations sont données par l'équation :

$$v_{jk} = \text{Cor}(X_j, \Psi_k) = \sqrt{\lambda_k} \cdot u_{jk}$$

où u_{jk} est la j-ième composante du vecteur propre u_k, et λ_k est la valeur propre associée.

Interprétation géométrique : Dans ce cercle de rayon 1, une variable dont la flèche atteint le bord est parfaitement représentée sur le plan ($v_{j1}^2 + v_{j2}^2 \approx 1$, toute sa variance est capturée par les 2 premiers axes). Une flèche très courte signale une variable mal projetée, dont l'information se trouve sur des axes de rang supérieur.

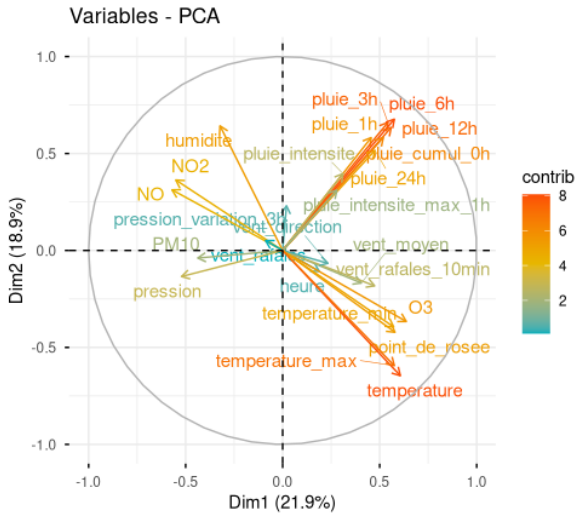


FIGURE 2 – Cercle des corrélations des variables *(Cliquez sur l'image pour l'agrandir).*

Analyse et interprétation des flèches : Le cercle des corrélations projette nos variables initiales sur le nouveau plan défini par l'ACP. C'est cette étape qui permet de donner un sens physique aux axes mathématiques :

- **Angles aigus (direction similaire) :** Traduisent des variables fortement corrélées positivement (ex : l'augmentation simultanée du NO et du NO_2).
- **Angles plats (180°) :** Indiquent une corrélation négative (ex : NO et O_3).
- **Angles droits (90°) :** Signalent une indépendance linéaire entre les variables (ex : température et pluie).

3.3.3 Projeté des individus et validation

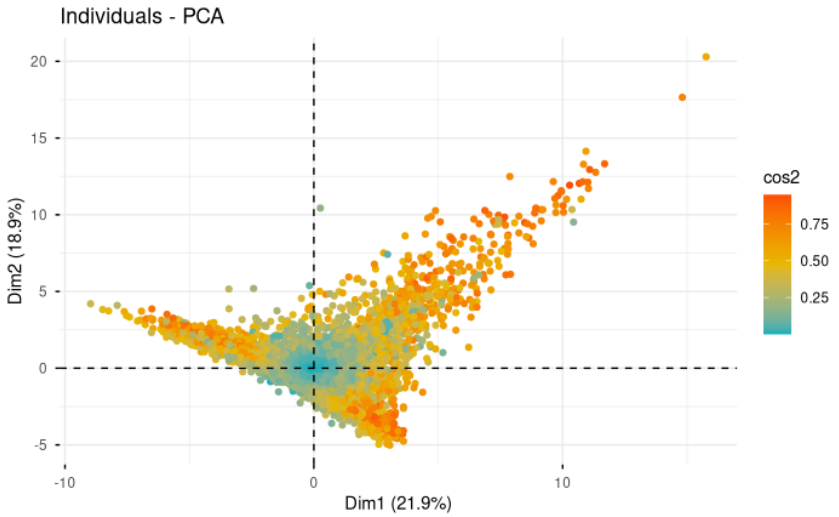


FIGURE 3 – Projection des individus (jours) *(Cliquez sur l'image pour l'agrandir).*

Analyse du nuage des individus : La fonction `fviz_pca_ind()` place nos relevés journaliers sur le nouveau repère en utilisant leurs scores. L'origine $(0, 0)$ représente le centre de gravité du

nuage, c'est-à-dire une journée aux conditions atmosphériques moyennes. Ce nuage s'interprète comme une carte typologique : deux points proches représentent des journées météorologiquement similaires, tandis que les points isolés en périphérie correspondent à des événements extrêmes (pics de pollution, tempêtes).

Validation par comparaison avec un bruit blanc : Pour s'assurer que nos axes capturent un véritable signal, nous simulons une matrice de "bruit blanc" (dimensions identiques, remplie aléatoirement selon une loi normale). Dans un tel bruit, aucune variable n'est corrélée et l'éboulis décroît doucement. La courbe de nos données réelles se situant nettement au-dessus de celle du bruit blanc pour les premiers axes, cela prouve de manière irréfutable que nos composantes modélisent une véritable structure environnementale.

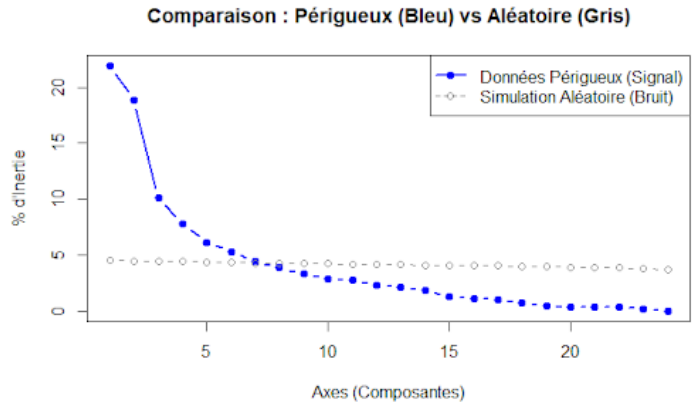


FIGURE 4 – Comparaison des inerties : données réelles de Périgueux vs. Bruit blanc aléatoire.

3.3.4 Synthèse des déductions environnementales

L'étude du plan principal (Axes 1 et 2), qui concentre près de 41 % de l'inertie totale, révèle une structuration très claire des dynamiques atmosphériques à Périgueux :

— **L'Axe 1 (21.9 %) - Le gradient des saisons et de l'ensoleillement :** Cet axe horizontal oppose diamétralement deux types de conditions. Du côté positif (été), on y retrouve la chaleur, le vent et de fortes quantités d'ozone (O_3). L'ozone est un polluant particulier : il n'est pas rejeté directement par les pots d'échappement, mais se forme quand d'autres gaz réagissent sous l'effet des rayons du soleil. Du côté négatif (hiver), on observe de l'humidité et un manque de vent. L'air a du mal à circuler, ce qui agit comme un couvercle : les polluants issus directement des fumées ou des moteurs (comme les gaz NO, NO_2, et les particules fines PM_{10}) s'accumulent au-dessus de la ville.

— **L'Axe 2 (18.9 %) - Le gradient de pluie :** Cet axe vertical est presque exclusivement construit par les relevés de précipitations. Il montre que la pluie suit sa propre logique, totalement indépendante des températures.

L'agencement des vecteurs confirme également des phénomènes physiques locaux, comme **l'effet de lessivage** (les pluies intenses sont légèrement opposées aux particules fines, contri-

buant à rabattre ces polluants) et le **cycle de l'Ozone** (destruction de l'Ozone par le monoxyde d'azote émis par le trafic, d'où leur opposition géométrique).

3.4 Conclusion sur l'ACP

L'Analyse en Composantes Principales s'est révélée être un outil d'une grande élégance mathématique pour déchiffrer la complexité de notre jeu de données. En réduisant l'espace initial à seulement deux dimensions, nous avons pu capturer près de 41% de l'inertie totale tout en conservant une très bonne interprétabilité physique. Les résultats démontrent que la qualité de l'air à Périgueux est structurée par la météorologie, nous permettant d'isoler deux situations à risque : la pollution estivale (pilotée par les fortes chaleurs et l'ensoleillement) et la pollution hivernale (marquée par la stagnation de l'air et l'accumulation de particules). Néanmoins, l'ACP repose sur un postulat mathématique strict : la linéarité des relations. Sachant que les interactions atmosphériques comportent souvent des dynamiques non-linéaires, il est légitime de supposer qu'une part non négligeable de la variance inexpliquée réside dans cette complexité que l'ACP ne peut algébriquement pas capturer. C'est cette limitation structurelle qui justifie notre basculement vers les architectures neuronales.

4 Autoencodeurs

4.1 De l'ACP aux autoencodeurs

L'Analyse en Composantes Principales s'est révélée un outil efficace pour résumer la structure de nos données. Cependant, cette méthode repose sur une hypothèse fondamentale : elle ne cherche que des relations **linéaires** entre les variables. Cette hypothèse peut s'avérer trop restrictive lorsque les données présentent des structures complexes.

C'est là qu'interviennent les **autoencodeurs** [2]. Un autoencodeur est un réseau de neurones artificiels dont le but n'est pas de prédire une étiquette, mais de **reconstruire ses propres données d'entrée** après les avoir fait passer par un goulot d'étranglement de dimension réduite. Ce goulot, appelé *espace latent*, joue exactement le même rôle que l'espace des composantes principales dans l'ACP : il contient la représentation compressée de l'observation.

Cette section établira d'abord un lien théorique entre l'ACP et les Autoencodeurs, avant de le vérifier empiriquement.

4.2 Cadre théorique et architecture

4.2.1 Architecture formelle et nombre de paramètres

Un autoencodeur à une couche cachée se décompose en trois éléments [3] :

— **L'encodeur** prend un vecteur d'entrée $z \in \mathbb{R}^p$ et le comprime en une représentation de dimension réduite $h \in \mathbb{R}^q$ (avec $q < p$) au travers d'une succession de L couches. En notant W_i la matrice de poids de la i-ème couche, le passage dans un encodeur strictement linéaire s'écrirait comme une composition de produits matriciels :

$$h = W_L W_{L-1} \dots W_1 z$$

— **La représentation latente** est le vecteur $h \in \mathbb{R}^q$. C'est un point spécifique dans l'espace latent qui contient l'information compressée d'une observation z.

— **Le décodeur** tente de reconstruire l'entrée originale z à partir de h via une nouvelle série de L' couches (symétriques, le plus souvent $L' = L$). Toujours dans le cas linéaire, la reconstruction s'écrit :

$$\hat{z} = W_{L+L'} \dots W_{L+1} h = (W_{L+L'} \dots W_{L+1})(W_L \dots W_1) z$$

Nombre de paramètres : Le nombre total de coefficients à apprendre n'est plus simplement $2pq$, mais la somme des éléments de chaque matrice W_i. Pour illustrer, notre architecture profonde finale ($24 \to 16 \to 8 \to 2$ pour l'encodeur et symétriquement pour le décodeur) totalise près de 1072 paramètres (en excluant les biais), contre seulement 96 pour le modèle à une couche cachée.

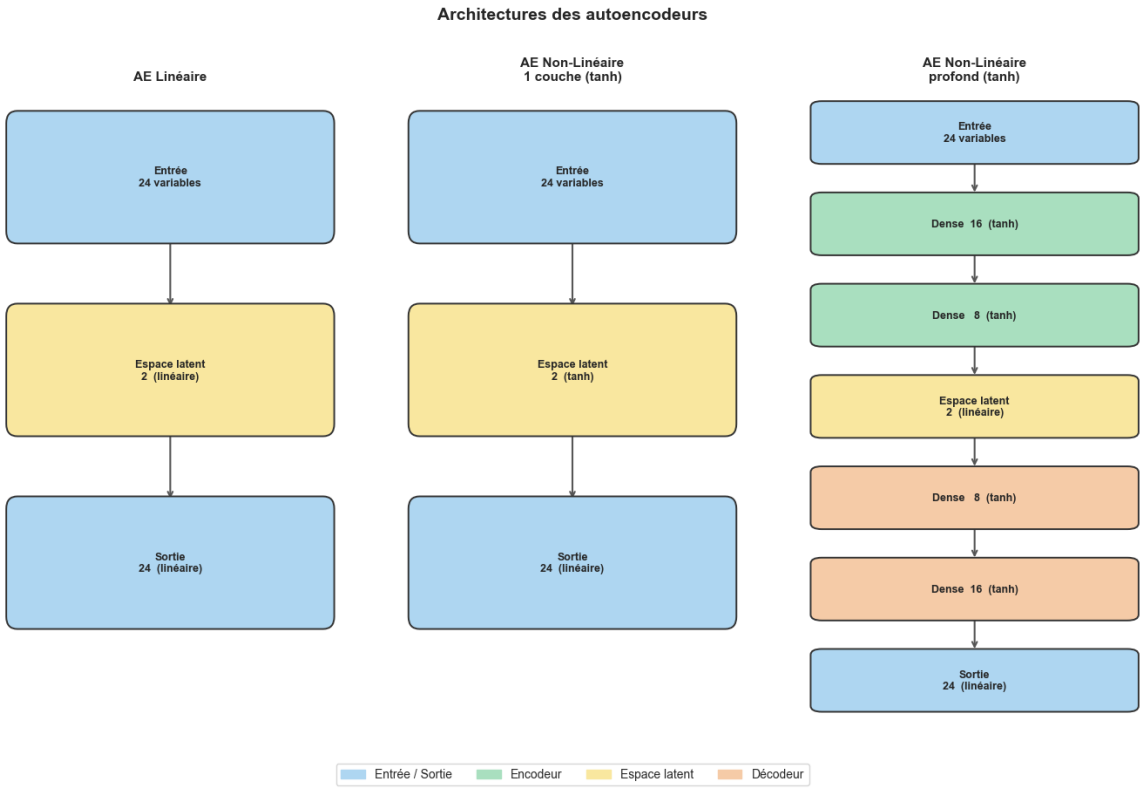


FIGURE 5 – Diagrammes des trois architectures d'autoencodeurs implémentées. De gauche à droite : linéaire, non-linéaire à 1 couche (`tanh`), et profond (`tanh`). L'espace latent (jaune) est de $q = 2$ dimensions.

4.2.2 Optimisation du modèle

Contrairement à l'ACP qui se résout par la diagonalisation exacte d'une matrice, l'autoencodeur est entraîné de manière itérative par rétropropagation du gradient. L'objectif est de trouver les matrices de poids W_1 et W_2 qui minimisent l'Erreur Quadratique Moyenne (MSE) (Preuve à l'**Annexe A.2**) :

$$\mathcal{L}(W_1, W_2) = \frac{1}{n} \sum_{i=1}^{n} ||z_i - \hat{z}_i||^2$$

Dans notre implémentation Python avec la librairie *Keras*, nous utilisons l'optimiseur **Adam**, une méthode de descente de gradient stochastique qui adapte dynamiquement le pas d'apprentissage.

4.2.3 Le théorème de Baldi et Hornik

Baldi et Hornik ont démontré en 1989 [1] : si un autoencodeur possède une unique couche cachée de dimension q, que toutes ses fonctions d'activation sont linéaires et que la fonction de coût est la MSE, alors la matrice W_2W_1 converge vers la projection orthogonale sur le sous-espace engendré par les q premiers vecteurs propres de Γ.

Une nuance essentielle : Ce théorème porte sur les *sous-espaces*, non sur les *vecteurs directeurs* [2]. L'ACP produit des composantes orthogonales classées par variance décroissante. L'autoencodeur linéaire ne fournit aucune de ces garanties : ses colonnes forment une base du

même sous-espace, mais non ordonnée. Le nuage projeté peut donc apparaître "tourné" par rapport à l'ACP.

4.2.4 Choix stratégique des fonctions d'activation

Dans les modèles non-linéaires, deux couches conservent systématiquement une activation **linéaire** :

— **L'espace latent :** Appliquer une fonction comme `ReLU` empêcherait les coordonnées de prendre des valeurs négatives. Or, avec des données centrées-réduites, une coordonnée négative a un sens physique (valeur sous la moyenne).

— **La couche de sortie :** Pour reconstruire un vecteur z standardisé, la sortie doit pouvoir couvrir tout $\mathbb{R}$. Toute fonction d'activation bornée sur le décodeur empêcherait la reconstruction correcte des valeurs extrêmes.

4.3 Application et validation empirique

Nous allons d'abord vérifier empiriquement l'équivalence stricte entre l'ACP et l'autoencodeur linéaire, puis nous augmenterons progressivement la profondeur et la non-linéarité du réseau pour observer leur apport sur la qualité de reconstruction.

4.3.1 L'autoencodeur linéaire

Comparaison visuelle des projections Nous avons entraîné un modèle linéaire ($p = 24, q = 2$) sur 100 époques. Les deux nuages de points présentent la même structure globale, mais la représentation de l'autoencodeur apparaît "tournée", conformément à la théorie.

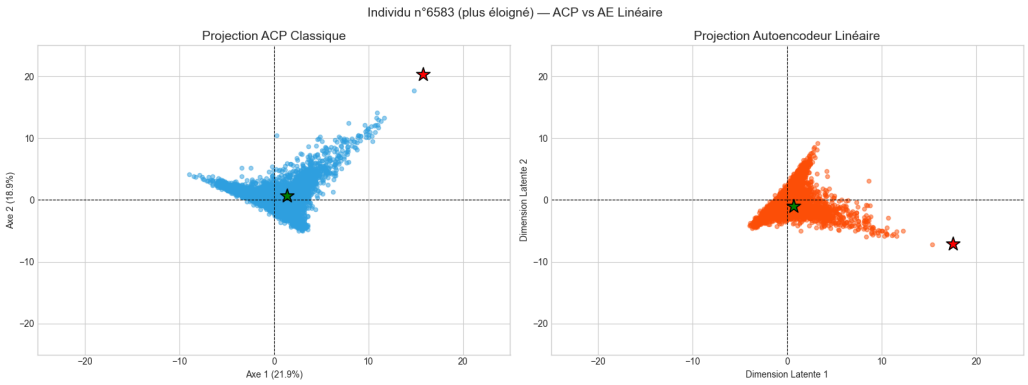


FIGURE 6 – Projections en dimension 2 : ACP classique (gauche) et autoencodeur linéaire (droite). L'individu atypique est marqué d'une étoile rouge *(Cliquez sur l'image pour l'agrandir).*

Pour rendre la nuance théorique concrète, nous isolons l'individu dont la distance au barycentre est maximale dans l'ACP (étoile rouge). Sa position *relative* au sein du nuage est identique dans les deux méthodes, preuve visuelle directe qu'elles extraient le **même sous-espace**, malgré des repères (bases) différents.

Comparaison des erreurs de reconstruction Pour valider numériquement cette équivalence, nous comparons les Erreurs Quadratiques Moyennes (MSE).

Méthode	MSE de reconstruction
ACP (2 composantes)	0,5919
Autoencodeur linéaire (dim. latente = 2)	0,5920

La quasi-identité de ces valeurs confirme que l'autoencodeur linéaire compresse et perd exactement la même quantité d'information que l'ACP.

4.3.2 L'autoencodeur non-linéaire à une couche (`tanh`)

Nous introduisons ensuite un cas intermédiaire : une unique couche non-linéaire avec activation `tanh` (préférée à `ReLU` pour sa sortie dans $[-1, 1]$). Sa MSE ($\approx 0{,}5926$) est quasi-identique à celle de l'ACP. Ce résultat montre qu'une seule couche non-linéaire, sans architecture profonde, n'apporte pas de gain expressif significatif sur ce jeu de données.

4.3.3 L'autoencodeur non-linéaire profond (`tanh`)

La véritable puissance de models réside dans l'alliance de la **non-linéarité** et de la **profondeur**. Nous construisons une structure symétrique en entonnoir :

— **Encodeur :** Dense(16, `tanh`) → Dense(8, `tanh`) → Dense(2, **linéaire**)

— **Décodeur :** Dense(8, `tanh`) → Dense(16, `tanh`) → Dense(24, **linéaire**)

Ce modèle profond atteint une MSE de reconstruction de 0,3078, soit une réduction drastique de l'erreur par rapport aux 0,5919 de l'ACP. Cela prouve l'existence de relations complexes (non-linéaires) entre la météo et la pollution de Périgueux que l'algèbre linéaire classique ne pouvait pas identifier.

4.4 Analyse comparative finale



FIGURE 7 – Comparaison des projections 2D : ACP (haut-gauche), AE linéaire (haut-droite), AE non-linéaire simple (bas-gauche) et AE profond (bas-droite). Les étoiles marquent l'individu le plus éloigné (rouge) et l'individu n°42 (verte) *(Cliquez sur l'image pour l'agrandir).*

Critère	**ACP**	**AE linéaire**	**AE NL (1 couche)**	**AE NL (profond)**
Relations modélisées	Linéaires	Linéaires	Non-linéaires	Non-linéaires
Interprétabilité	Forte	Partielle	Faible	Nulle
Unicité de la solution	Oui	Non	Non	Non
MSE globale	0,5919	0,5920	0,5926	**0,3078**
Optimisation	Exacte	Itérative	Itérative	Itérative
Activation latente	—	Linéaire	Non-linéaire	Linéaire

TABLE 1 – Tableau comparatif des quatre méthodes testées.

Bilan : L'autoencodeur non-linéaire profond réduit la perte d'information de près de 48 % par rapport à l'ACP. Néanmoins, ce gain de précision se paie au prix fort : l'interprétabilité physique directe des axes (via le cercle des corrélations par exemple) disparaît totalement, et l'optimisation devient sensible au choix des hyperparamètres architecturaux.

4.5 Conclusion générale

Ce projet nous a permis de confronter deux visions fondamentales de la réduction de dimension en apprentissage non supervisé : l'approche algébrique classique et l'approche neuronale moderne. Le point crucial de notre étude réside dans le théorème de Baldi et Hornik, qui établit un pont mathématique fascinant entre ces deux mondes : l'ACP n'est en réalité que la solution analytique d'un autoencodeur strictement linéaire.

Sur le plan empirique, le passage à la profondeur et à la non-linéarité a tenu ses promesses en réduisant l'Erreur Quadratique Moyenne (MSE) de près de 48%. Le réseau profond est parvenu à capturer les subtilités chimiques et météorologiques de Périgueux qui échappaient à la projection orthogonale de l'ACP. Cependant, cette performance brute s'accompagne d'une perte totale d'interprétabilité. L'autoencodeur agit comme une boîte noire : il compresse mieux l'information, mais son espace latent perd le sens physique et géométrique direct qu'offrait le cercle des corrélations. En définitive, cette étude démontre qu'il n'existe pas de méthode de réduction absolue, mais un compromis inévitable : l'ACP demeure l'outil maître pour comprendre et expliquer formellement les données, tandis que l'autoencodeur profond s'impose lorsque l'objectif exclusif est la minimisation stricte de la perte d'information.

5 Difficultés rencontrées et Organisation du groupe

La mise en œuvre de ce projet, mêlant approches statistiques classiques et apprentissage profond, a soulevé plusieurs défis méthodologiques et techniques que nous détaillons ici.

5.1 Défis techniques et limites des modèles

— **Optimisation des autoencodeurs :** Contrairement à l'ACP qui offre une solution analytique unique, l'entraînement des réseaux de neurones est sujet à plusieurs aléas. Trouver la profondeur optimale et le nombre de neurones par couche a nécessité de nombreux tests empiriques pour éviter le *sous-apprentissage* ou le *sur-apprentissage*. Le réglage du nombre d'époques a été crucial pour stabiliser la perte (MSE).

— **Compromis précision-interprétabilité :** Le passage de l'ACP à l'autoencodeur profond a mis en lumière le compromis entre précision et interprétabilité. Si le modèle profond réduit l'erreur de reconstruction de près de 50%, il devient une « boîte noire ». Nous avons rencontré des difficultés pour corréler les dimensions de l'espace latent avec des phénomènes physiques réels, contrairement au cercle des corrélations de l'ACP.

— **Qualité et standardisation des données :** Le jeu de données de Périgueux présentait des échelles très hétérogènes (µg/m^3 vs hPa). La standardisation (centrage-réduction) a été une étape critique : sans elle, les variables à forte variance numérique auraient totalement masqué l'influence des autres variables, faussant l'analyse.

5.2 Organisation du travail de groupe

La réussite de ce projet repose sur une coordination étroite entre les six membres de l'équipe. Nous avons adopté une structure agile pour répondre à la dualité théorique et numérique du sujet :

— **Communication et suivi :** Pour assurer une réactivité maximale, l'ensemble des échanges s'est fait par message/mail. Des points de situation réguliers avec notre professeur référent nous ont permis de lever les points de blocage en temps réel et de maintenir une cohérence globale dans la rédaction du rapport.

— **Répartition des groupes :** Nous avons divisé le travail en deux groupes de travail complémentaires :

  – *Groupe Mathématique :* Chargé de la formalisation théorique de l'ACP, de l'étude de la matrice de corrélation Γ et de la rédaction des preuves en annexe.

  – *Groupe Informatique :* Responsable de la manipulation du jeu de données sous R (*FactoMineR*) et du développement des architectures d'autoencodeurs sous Python (*Keras/TensorFlow*).

— **Mutualisation et revue :** Bien que les tâches aient été divisées, chaque membre a participé à la phase de revue croisée. Les membres du pôle informatique ont expliqué les résultats des codes aux théoriciens, et inversement, afin que chaque auteur maîtrise l'intégralité du sujet, de l'algèbre linéaire aux réseaux de neurones.

6 Références

[1] P. Baldi et K. Hornik, *Neural networks and principal component analysis : Learning from examples without local minima*, Neural Networks, vol. 2, no. 1, pp. 53–58, 1989.

[2] H. Bourlard et Y. Kamp, *Auto-association by multilayer perceptrons and singular value decomposition*, *Biological Cybernetics*, vol. 59, no. 4–5, pp. 291–294, 1988.

[3] I. Goodfellow, Y. Bengio et A. Courville, *Deep Learning*, MIT Press, 2016. Disponible en ligne : `https://www.deeplearningbook.org`

[4] D. E. Rumelhart, G. E. Hinton et R. J. Williams, *Learning representations by back-propagating errors*, *Nature*, vol. 323, pp. 533–536, 1986.

[5] D. P. Kingma et J. Ba, *Adam : A method for stochastic optimization*, arXiv preprint arXiv :1412.6980, 2014.

[6] M. E. Tipping et C. M. Bishop, *Probabilistic Principal Component Analysis*, Journal of the Royal Statistical Society : Series B (Statistical Methodology), vol. 61, no. 3, pp. 611–622, 1999.

[7] F. Chollet et al., *Keras*, GitHub, 2015. Disponible en ligne : `https://github.com/keras-team/keras`

[8] Y. LeCun, Y. Bengio et G. Hinton, *Deep learning*, *Nature*, vol. 521, pp. 436–444, 2015.

[9] I. T. Jolliffe, *Principal Component Analysis*, Springer Series in Statistics, 2nd Edition, 2002.

[10] P. Vincent, H. Larochelle, I. Lajoie, Y. Bengio et P.-A. Manzagol, *Stacked denoising autoencoders : Learning useful representations in a deep network with a local denoising criterion*, *Journal of Machine Learning Research*, vol. 11, pp. 3371–3408, 2010.

[11] F. Husson, S. Lê et J. Pagès, *Analyse de données avec R*, Collection "Pratique de la statistique", 2016.

Annexe A : Démonstrations mathématiques

A.1 Optimisation et maximisation de la variance (ACP)

L'objectif de cette preuve est de démontrer que la recherche du sous-espace E_q de dimension q qui minimise la somme des distances orthogonales résiduelles équivaut à maximiser la variance projetée, et que ce problème se résout par la diagonalisation de la matrice de corrélation Γ.

1. Décomposition géométrique de l'inertie

Considérons un individu $\mathbf{z}_i$ (centré et réduit) dans l'espace d'origine $\mathbb{R}^p$. On cherche à projeter cet individu sur un sous-espace E_q de dimension $q < p$. Notons $\hat{\mathbf{z}}_i$ sa projection orthogonale sur E_q.

D'après le théorème de Pythagore appliqué au triangle rectangle formé par l'origine, la projection et le point initial, la norme au carré de l'observation se décompose en :

$$\|\mathbf{z}_i\|^2 = \|\hat{\mathbf{z}}_i\|^2 + \|\mathbf{z}_i - \hat{\mathbf{z}}_i\|^2 \tag{1}$$

En sommant sur l'ensemble des n individus du jeu de données, nous obtenons :

$$\sum_{i=1}^{n} \|\mathbf{z}_i\|^2 = \sum_{i=1}^{n} \|\hat{\mathbf{z}}_i\|^2 + \sum_{i=1}^{n} \|\mathbf{z}_i - \hat{\mathbf{z}}_i\|^2 \tag{2}$$

L'analogie physique ou statistique est immédiate :

— $\sum \|\mathbf{z}_i\|^2$ représente l'inertie totale du nuage de points (qui est fixe).

— $\sum \|\hat{\mathbf{z}}_i\|^2$ représente l'inertie expliquée par le sous-espace (la variance projetée).

— $\sum \|\mathbf{z}_i - \hat{\mathbf{z}}_i\|^2$ représente l'inertie résiduelle (la somme des distances orthogonales au carré).

L'inertie totale étant une constante propre aux données, **minimiser la distance orthogonale résiduelle revient strictement à maximiser la variance projetée**.

2. Formulation algébrique avec la Trace

Soit U_q la matrice de taille $p \times q$ dont les colonnes forment une base orthonormée du sous-espace E_q. La contrainte d'orthonormalité s'écrit $U_q^T U_q = I_q$, où I_q est la matrice identité de dimension q.

La projection de la matrice des données Z (de taille $n \times p$) sur ce sous-espace est donnée par ZU_q. La matrice de variance-covariance (ici de corrélation puisque les données sont centrées et réduites) des données projetées s'écrit :

$$\Gamma_{proj} = \frac{1}{n}(ZU_q)^T(ZU_q) = U_q^T \left(\frac{1}{n} Z^T Z\right) U_q = U_q^T \Gamma U_q \tag{3}$$

La variance totale capturée par le sous-espace E_q est la somme des variances sur chaque axe projeté, ce qui correspond mathématiquement à la trace de cette matrice. Le problème

d'optimisation se formalise donc ainsi :

$$\max_{U_q} \mathrm{Tr}(U_q^T \Gamma U_q) \quad \text{sous la contrainte} \quad U_q^T U_q = I_q \tag{4}$$

3. Résolution par les multiplicateurs de Lagrange

Pour résoudre ce problème sous contrainte, nous introduisons la matrice Λ des multiplicateurs de Lagrange (qui est une matrice symétrique de dimension $q \times q$). Le Lagrangien s'écrit :

$$\mathcal{L}(U_q, \Lambda) = \mathrm{Tr}(U_q^T \Gamma U_q) - \mathrm{Tr}(\Lambda(U_q^T U_q - I_q)) \tag{5}$$

En dérivant par rapport à la matrice U_q et en égalant à zéro pour trouver le point critique, nous obtenons :

$$\frac{\partial \mathcal{L}}{\partial U_q} = 2\Gamma U_q - 2U_q\Lambda = 0 \implies \Gamma U_q = U_q\Lambda \tag{6}$$

Cette équation matricielle montre que les colonnes de U_q doivent être des vecteurs propres de la matrice de corrélation Γ, et que les éléments diagonaux de Λ sont les valeurs propres associées.

4. Conclusion

En réinjectant cette égalité dans l'expression de la variance à maximiser, on obtient :

$$\mathrm{Tr}(U_q^T \Gamma U_q) = \mathrm{Tr}(U_q^T U_q \Lambda) = \mathrm{Tr}(\Lambda) = \sum_{k=1}^{q} \lambda_k \tag{7}$$

Pour maximiser cette quantité, il suffit donc de retenir les q vecteurs propres $\mathbf{u}_k$ associés aux q plus grandes valeurs propres $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_q$ de la matrice Γ.

A.2 Équivalence entre l'Autoencodeur Linéaire et l'ACP

L'objectif est de démontrer que la minimisation de la perte d'un autoencodeur linéaire à une couche cachée est mathématiquement équivalente à la recherche du sous-espace principal de l'ACP.

1. Formulation de l'Autoencodeur Linéaire

Soit $Z \in \mathbb{R}^{n \times p}$ la matrice des données centrées-réduites. Un autoencodeur linéaire avec q neurones sur la couche cachée effectue deux transformations :

— **Encodage :** $H = ZW_1$ (où $W_1 \in \mathbb{R}^{p \times q}$)

— **Décodage :** $\hat{Z} = HW_2$ (où $W_2 \in \mathbb{R}^{q \times p}$)

La fonction de coût (MSE) à minimiser est :

$$L(W_1, W_2) = \|Z - \hat{Z}\|_F^2 = \|Z - ZW_1W_2\|_F^2$$

où $\|\cdot\|_F$ désigne la norme de Frobenius.

2. Lien avec la projection orthogonale

Posons $P = W_1 W_2$. Pour que $\hat{Z}$ soit la meilleure approximation de Z au sens des moindres carrés, P doit être une matrice de projection de rang q sur le sous-espace E_q.

La théorie de l'approximation de rang faible (théorème de *Eckart-Young-Mirsky*) stipule que la meilleure approximation d'une matrice Z par une matrice de rang q est obtenue en conservant les q plus grandes valeurs singulières de sa décomposition en valeurs singulières (SVD).

3. Décomposition en Valeurs Singulières (SVD)

La SVD de Z s'écrit $Z = U\Sigma V^T$. La matrice de corrélation est alors :

$$\Gamma = \frac{1}{n} Z^T Z = \frac{1}{n}(V\Sigma U^T)(U\Sigma V^T) = V\left(\frac{\Sigma^2}{n}\right)V^T$$

Ici, les colonnes de V sont les vecteurs propres de Γ (les composantes principales de l'ACP) et les éléments de $\frac{\Sigma^2}{n}$ sont les valeurs propres λ_k.

4. Conclusion

Bien que l'entraînement par descente de gradient (Adam) puisse aboutir à des poids W_1 et W_2 différents des vecteurs propres de l'ACP à cause de la non-unicité des bases (les poids peuvent être une version tournée/scalée des vecteurs propres), le **sous-espace** s'étendant sur les colonnes de W_2 (l'espace latent) est identique à celui défini par les q premiers vecteurs propres de l'ACP.

L'autoencodeur minimise ainsi la même distance orthogonale que l'ACP :

$$\min_{W_1, W_2} \|Z - ZW_1W_2\|^2 \iff \max_{U_q} \mathrm{Tr}(U_q^T \Gamma U_q)$$

Annexe B : Graphiques en haute résolution

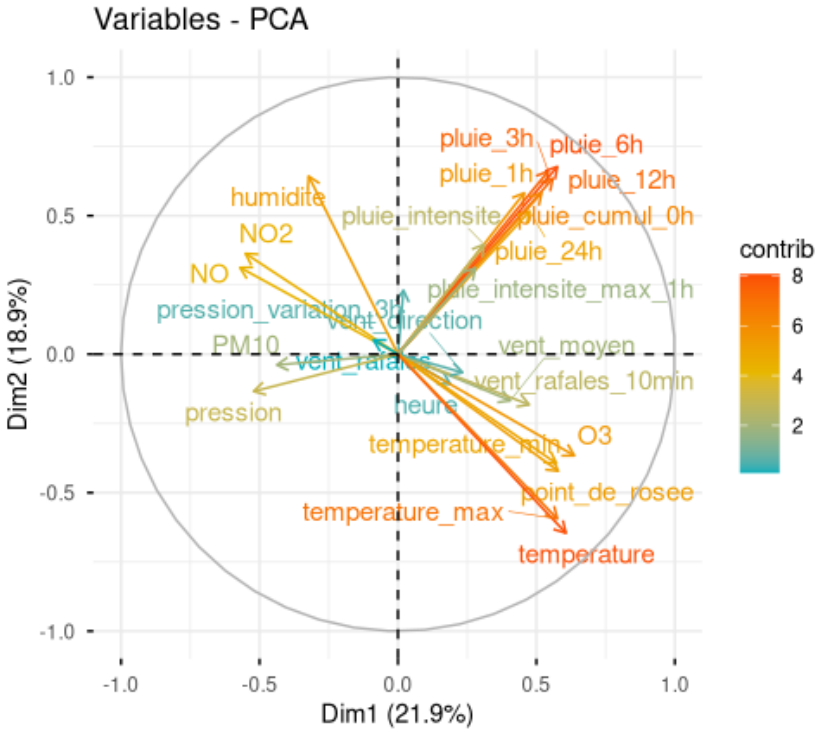


FIGURE 8 – Cercle des corrélations des variables.



FIGURE 9 – Projection des individus (jours).

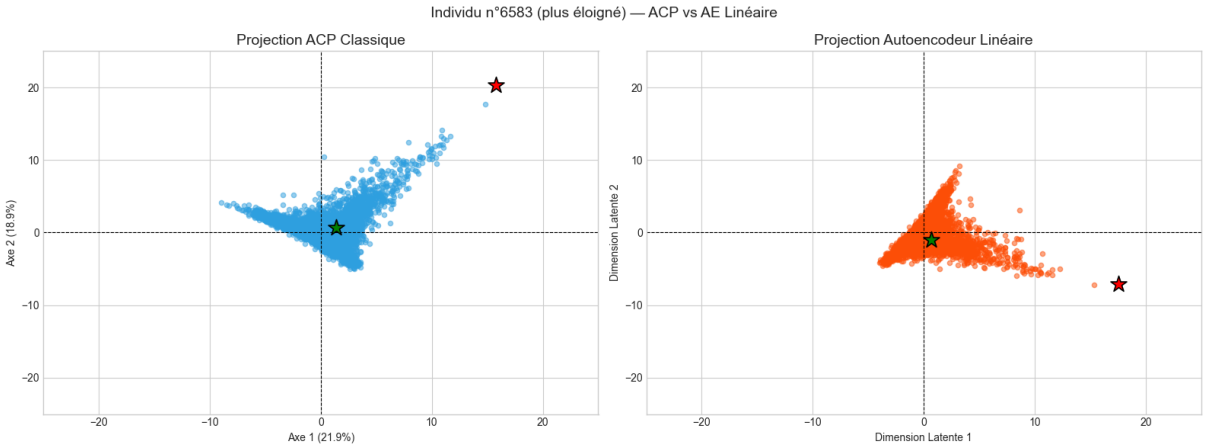


FIGURE 10 – Projections en dimension 2 : ACP classique (gauche) et autoencodeur linéaire (droite). L'individu atypique est marqué d'une étoile rouge.

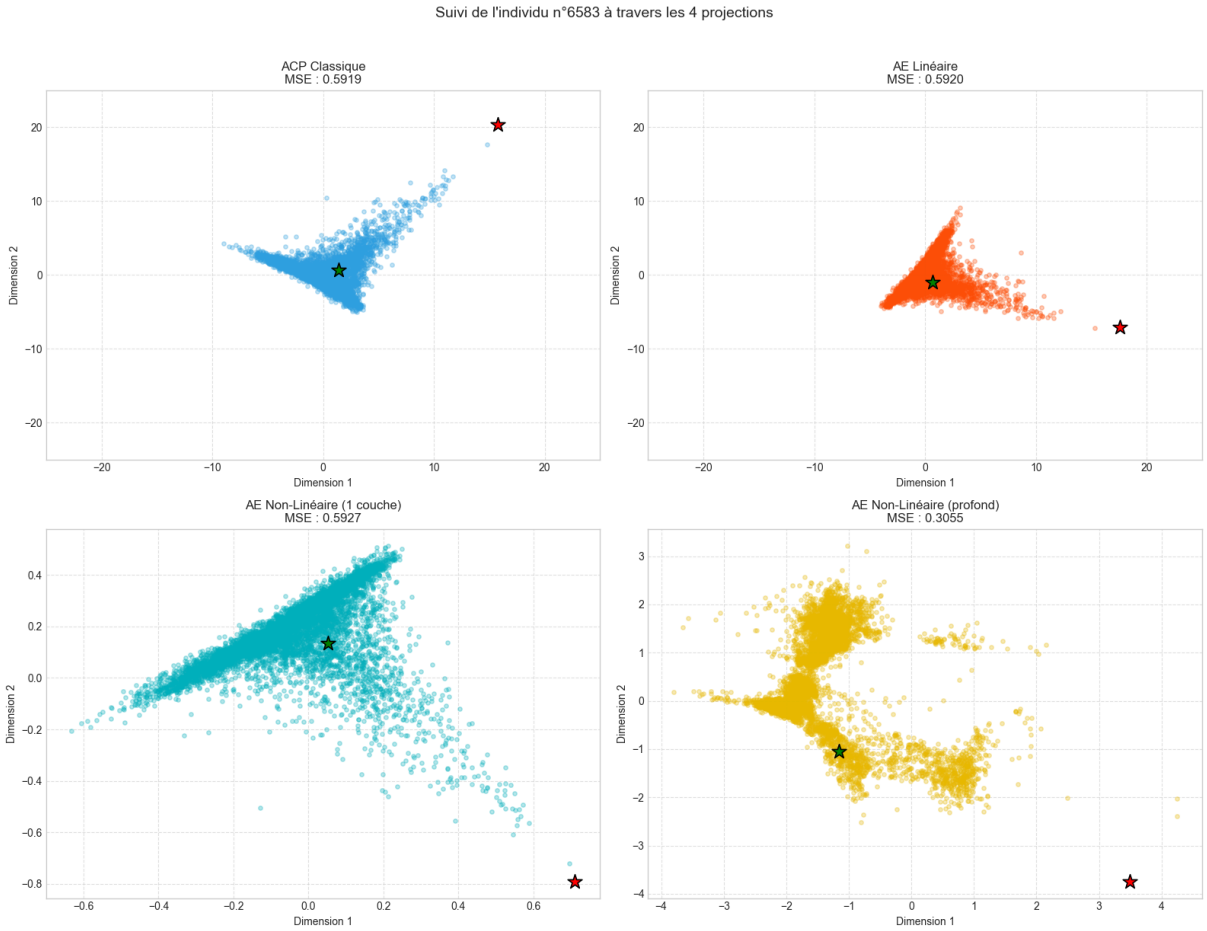


FIGURE 11 – Comparaison des projections 2D : ACP (haut-gauche), AE linéaire (haut-droite), AE non-linéaire simple (bas-gauche) et AE profond (bas-droite). Les étoiles marquent l'individu le plus éloigné (rouge) et l'individu n°42 (verte).